

Note méthodologique

Projet 7

Implémentez un modèle de scoring

1.....	Introduction	
.....		3
2. Méthode d'entraînement des modèles (2 pages maxi)		4
2.1 Preprocessing :.....		4
2.2 Modélisations		5
3. Evaluation des modèles.....		7
3.1 Matrice de confusion.....		7
3.2 Les scores		8
4. Interprétabilité du modèle.....		10
5. Limites et améliorations possibles.....		10

1. Introduction

Objectif de la mission :

- **Mettre en oeuvre un outil de "scoring credit"** afin de calculer la probabilité qu'un client rembourse son crédit, puis classer et notifier la demande par un accord ou un refus.
- **Mettre en oeuvre un dashboard interactif** à destination des chargés de clientèle.

Pour mettre en place un modèle efficace, il convient d'effectuer en premier lieu une Analyse Exploratoire des Données. Cela permet la bonne compréhension de l'objectif de la mission, l'identification de variables pertinentes (mesurer les corrélations entre les variables), le nettoyage de valeurs qui présentent des valeurs aberrantes ou encore la mise en place de features engineering.

Cette analyse a été adaptée d'une analyse effectuée sur Kaggle disponible à l'adresse ci-dessous :

<https://www.kaggle.com/code/willkoehrsen/start-here-a-gentle-introduction/notebook>

[date de consultation 30/04/2022]

Plusieurs éléments de cette analyse sont ressortis dont voici quelques exemples :

- **la cible** : [qui indique si une personne a remboursé (0) ou non (1) son crédit] présente un fort déséquilibre qui conviendra de prendre en compte dans la mise en place des modélisations.




Fig 1 : Répartition des clients suivant la variable cible dans le jeu d'entraînement : client ayant remboursé [0] vs clients n'ayant pas remboursé [1]

Si le modèle est laissé sans ajustement de la cible, il y aura un surajustement qui favorisera sûrement l'accord de prêt.

- **les transformations des variables catégorielles** : soit avec le label encoder (pour les variables à 2 catégories) et le one hot encoder pour les variables à + de 2 catégories)

- La **conversion de la variable Days_birth**. Les valeurs sont négatives, car elles sont enregistrées en nombre de jour par rapport à la demande de prêt. Une conversion a été effectuée et les âges vont de 20 à 69 ans, il n'apparaît pas de données aberrantes
- **Détection d'anomalies pour la variable Days_employment**. Certains clients auraient travaillé plus de 1000 ans
- **Variables d'intérêt** : ext_1, ext_2, ext_3
- **Features engineering** :

Construction de 35 variables polynomiales pour les variables : ext_1, ext_2, ext_3 et DAYS_BIRTH

CREDIT_INCOME_PERCENT : le pourcentage du montant du crédit par rapport au revenu du client.

ANNUITY_INCOME_PERCENT : le pourcentage de l'annuité du prêt par rapport au revenu du client.

CREDIT_TERM : la durée du paiement en mois (l'annuité étant le montant mensuel dû).

DAYS_EMPLOYED_PERCENT : le pourcentage des jours d'emploi par rapport à l'âge du client.

Cette étude a été réalisée sur Python, toutes les librairies utilisées sont indiquées dans les notebooks. Le notebook d'analyse qui comprend tous les détails est joint dans le dossier global.

2. Méthode d'entraînement des modèles

Dans cette étude, l'objectif est d'apporter un modèle qui calcule la probabilité de défaut de paiement d'un client en vue d'accepter ou de refuser sa demande de prêt selon un seuil définit.

La catégorie des algorithmes de classification supervisées a été utilisée pour arriver à une classification binaire, 1 accepter : peu de risque de défaut de paiement, 0 : refuser, risque trop important de défaut de paiements.

La problématique métier attire notre attention au fait que l'on souhaite : limiter le nombre de faux positifs. C'est-à-dire limiter le nombre de faux bons clients qui engendreraient des coûts à la banque.

2.1 Preprocessing :

Avant la mise en place des algorithmes, une étape de pre-processing est indispensable. Cette étape se définit par :

- Imputer les valeurs manquantes
- Transformer les booléens en entières,
- Centrer-réduire le jeu de données
- Diviser le jeu de données en 2 : train et test
- Équilibrer les données

L'équilibre du jeu de données est nécessaire pour éviter le sur ou sous entraînement des modèles.

La stratégie d' "undersampling" a été pris en compte. Cette stratégie est motivée par une forte importance du jeu de données (246 000 individus au total dont 19860 pour la catégorie la plus faible) et un temps de calcul qui sera diminué.

Il y a ainsi 19860 individus dans chacune des 2 catégories.

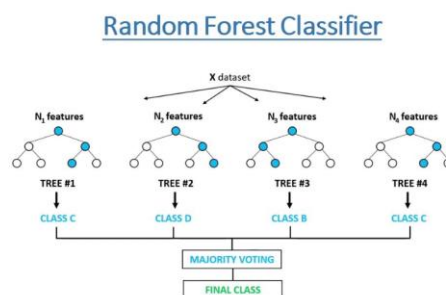
2.2 Modélisations

3 modèles de classifications ont été testés : **la régression logistique, le Random-Forest classifier et le LGBM.**

- **Regression logistique** : " La **régression logistique** est un **modèle** statistique permettant d'étudier les relations entre un ensemble de variables qualitatives X_i et une variable qualitative Y . Il s'agit d'un **modèle** linéaire généralisé utilisant une fonction **logistique** comme fonction de lien

Pour plus d'information : <https://medium.com/tell-ia/la-r%C3%A9gression-logistique-expliqu%C3%A9e-%C3%A0-ma-grand-m%C3%A8re-52a2ab30788>

- **Random forest classifier** : cet algorithme amorce les données en choisissant au hasard des sous-échantillons pour chaque itération d'arbres



Pour plus d'information : <https://medium.com/analytics-vidhya/random-forest-classifier-and-its-hyperparameters-8467bec755f6>

- **LigthGBM** (Light Gradient Boosting Machine) : algorithme basé sur des arbres de décision et utilisé pour le classement. Il se base sur la descente de gradient (technique d'optimisation pour réduire la fonction de perte en suivant la pente à travers une taille de pas fixe).

<https://towardsdatascience.com/what-makes-lightgbm-lightning-fast-a27cf0d9785e>

L'entraînement du modèle a pris en compte une **grid search CV** qui permet de sélectionner les meilleurs hyper-paramètres en testant différents paramètres aléatoirement. Les paramètres ont également été optimisés grâce à une recherche par validation croisée et qui est basée sur le score, fbeta score=2. Cette fonctionnalité a été fait grâce à la fonction RandomizedSearchCV (librarie sklearn).




Fig X: exemple théorique de recherches des meilleurs hyperparamètres aléatoirement

La cross-validation est une technique qui permet de limiter les biais en sous échantillonnant le jeu de données en différents blocs.

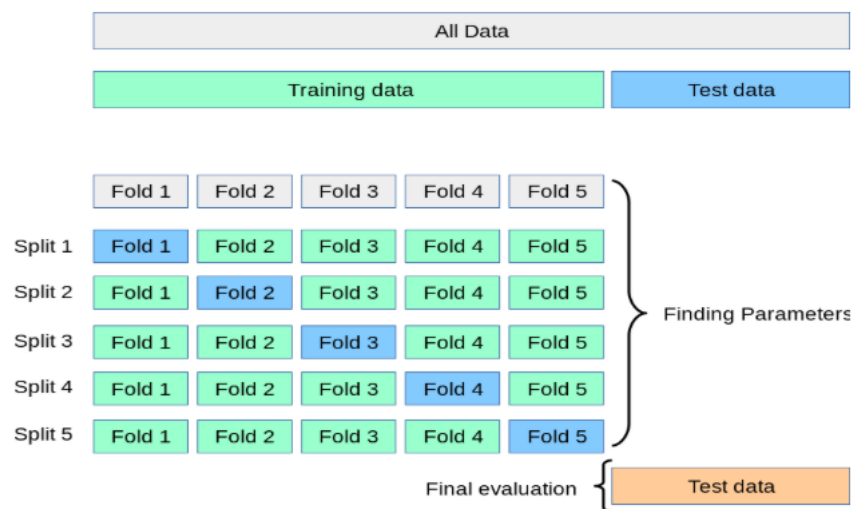


Fig X : exemple théorique de divisions du jeu de données en plusieurs sous-ensemble.


Une fois les meilleurs paramètres sélectionnés, la **fonction .predict_proba** a été utilisée pour entraîner le modèle et ainsi obtenir une valeur de probabilité de défaut de paiement.

Enfin, l'étape suivante a consisté à **définir un seuil** qui permet de classer les probabilités en 2 catégories (l'individu va rembourser, ou non).

La définition du seuil a été définie grâce à la sélection du score beta F2 maximum. En effet, plus le score F2 est fort, plus les faux négatifs (un faux bon client) sont faibles.

On va regarder pour quel score compris entre 0 et 1 le fbeta score est le plus élevé. Dans le graph si dessous, le seuil de 0.5 apparait comme le meilleur score correspondant au fbeta score le plus élevé.

Pour plus d'informations : <https://www.yourdatateacher.com/2021/06/14/are-you-still-using-0-5-as-a-threshold/>



3. Evaluation des modèles

3.1 Matrice de confusion

La matrice de confusion permet de résumer les performances d'un modèle et voir les erreurs de prédiction commises.

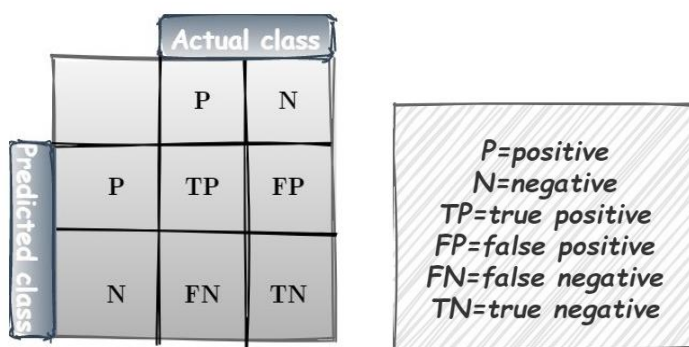
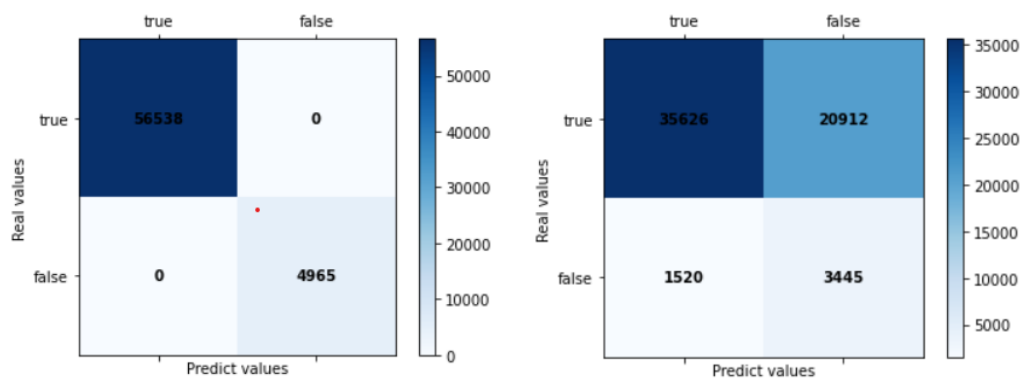


Fig xX : matrice de confusion théorique

Ci-dessous, les matrices de confusion pour les différents modèles testés.



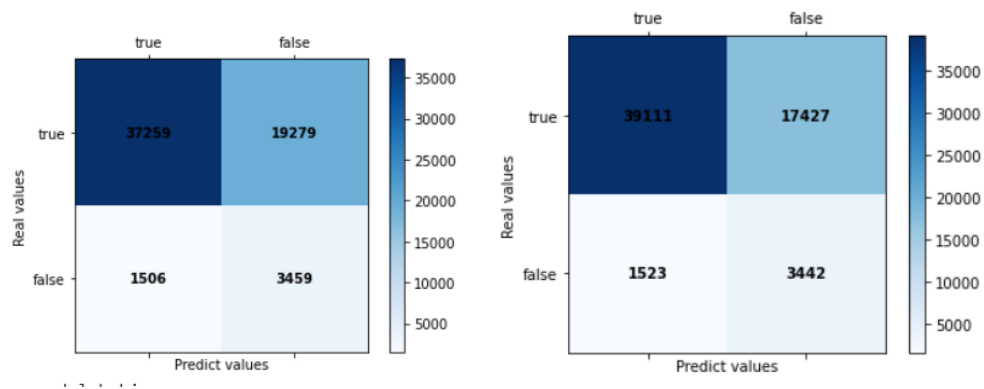


Fig X : Matrice de confusions sur la partie test.

À gauche, la matrice de confusion réelles et à gauche pour l'algorithme LGBM

La matrice de confusion pour l'algorithme LGBM indiquent le nombre de faux positifs le moins élevé.

3.2 Les scores

Pour mémoire voici quelques définitions :

- Précision : Coeff détermine que quand le classifieur déclare une prédiction à 1, il a raison à X %
- Rappel : Coeff qui détermine le pourcentage de détection des 1 du classifieur

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

- F1 score, est la moyenne de la précision et du rappel

$$F_1 = \frac{2}{\frac{1}{Precision} + \frac{1}{Recall}} = \frac{2TP}{2TP + FP + FN}$$

- F2 score : définir combien le rappel est important par rapport à la précision.

$$F_2 = \frac{2TP}{2TP + 0.2FP + 0.8FN}$$

F2 (Image de l'auteur)

- Fbeta: Cette mesure permet de définir combien le rappel est important par rapport à la précision.
-

$$F_{\beta} = \frac{1 + \beta^2}{\frac{\beta^2}{Recall} + \frac{1}{Precision}}$$

Pour plus d'informations, veuillez consulter cet article qui détaille toutes ces notions.
<https://towardsdatascience.com/is-f1-the-appropriate-criterion-to-use-what-about-f2-f3-f-beta-4bd8ef17e285>

Le **F2 score a été la métrique d'évaluation principale**. En effet, plus le score F2 est fort, plus les faux négatifs (un faux bon client) sont faibles. Ci-dessous, voici le récapitulatif des différents scores pour la comparaison des 3 modèles.

	accuracy	precision	recall	f1_score	f2_score	f3_score
LR	0.664	0.153	0.698	0.251	0.408	0.515
RF	0.691	0.161	0.669	0.259	0.410	0.509
LGBM	0.704	0.169	0.682	0.271	0.425	0.523

Au vu des résultats, le LGBM a été sélectionné pour la mission. Il présente le F2-score le plus élevé. Globalement, les 3 algorithmes indiquent des résultats similaires.

A titre de comparaison, voici les résultats des scores s'il il n'y avait pas eu la mise en place d'un équilibrage de la cible. Les accuracy sont très élevés mais cela nous indique un surapprentissage du modèle. En effet, le modèle prédit comme si tout le monde remboursait son crédit et on constate un très fort nombre de faux positif, plus élevé que dans le modèle avec équilibrage des classes.

Courbe ROC :

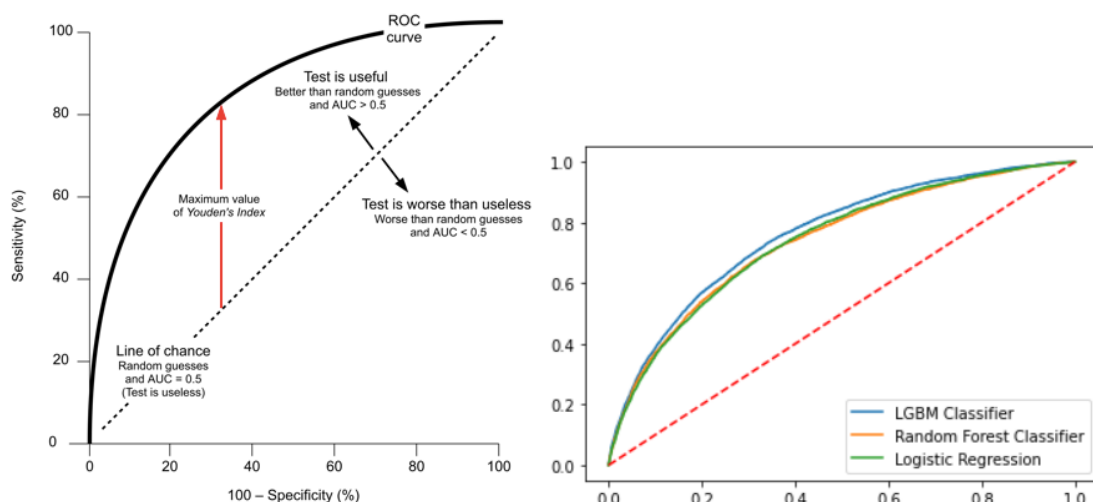


Fig XX : courbe ROC théorique (à gauche) et courbe ROC appliquée aux modélisations (à droite)


4. Interprétabilité du modèle

L'interprétabilité du modèle a été observée avec la librairie SHAP (**SH**apley **A**dditive **e**x**P**lanations).


“Il relie l'allocation optimale des crédits aux explications locales en utilisant les valeurs classiques de Shapley de la théorie des jeux et leurs extensions associées (voir les [articles](#) pour les détails et les citations)”. <https://shap.readthedocs.io/en/latest/index.html> [Date de consultation 28/04/2022].



Interprétation globale == interprété le modèle en lui-même == features importances



Interprétation locale ==> expliquer au client pourquoi on ne lui accorde pas de crédit



5. Limites et améliorations possibles

Plusieurs éléments seraient à approfondir ou à améliorer :

- **Accorder plus de temps à l'analyse exploratoire.** Par exemple, le kaggle utilisé qui a été noté gold et qui a fait un travail très intéressant présentent une erreur importante : avoir laisser l'id du client en variable numérique.
- **Sélection des features à confirmer par des équipes métiers,** ce qui permettrait d'améliorer également l'interprétabilité des modèles.
- **Détailler encore plus les hyperparamètres** des modèles.
- **Analyser les faux positifs.**
- **Classification multiple.** Par exemple, il est possible d'imaginer plusieurs classes



- **Limites éthique et juridique :** Le data scientist a un rôle de sensibilisation auprès des équipes techniques. Par exemple, l'algorithme retenu ne doit pas créer de discrimination. Au vu du temps qui m'a été accordé pour mettre en place ce projet, je n'ai pas pu analyser d'autres biais de représentativité qui pourrait être présent dans ce jeu de données. A noter qu'en 2015, Amazon a stoppé ses algorithmes de recrutement de personnel après 1 an d'utilisation car ils se sont aperçus que les données d'entraînement n'étaient pas bien équilibrées et favoriser les recrutements masculins.
- Autres pistes : **Utilisation de deep Learning**, par exemple des auto-encodeurs.

D'autres jeux de données avec des variables financières générales qui suit par exemple les crises financières

<https://towardsdatascience.com/deep-learning-in-finance-is-this-the-future-of-the-financial-industry-a29b561031e9>